Influencia de los hábitos cotidianos en el rendimiento académico: Un enfoque Bayesiano Robusto y Multinivel

Influence of Daily Habits on Academic Performance: A Robust and Multilevel Bayesian Approach

Santiago Sandoval Cortés[1,*] and **Miguel David Moreno Lozano**[2,*]

[1] Pregrado Ciencia de Datos Universidad Externado, Bogotá - Colombia

[2]Pregrado Ciencia de Datos Universidad Externado, Bogotá - Colombia

[*]santiago.sandoval1@est.uexternado.edu.co , miguel.moreno2@est.uexternado.edu.co

May 18, 2026

RESUMEN

El presente artículo de investigación analiza la influencia de los hábitos de vida cotidiana —horas de estudio independiente, asistencia a clases, horas de sueño y actividades de ocio— sobre el rendimiento académico de estudiantes universitarios, medido a través del promedio general acumulado (CGPA). Utilizando una muestra representativa de 5,000 registros de estudiantes, se estructuró un marco probabilístico avanzado mediante una **Regresión Lineal Bayesiana Robusta con verosimilitud T-Student** para mitigar la sensibilidad a valores atípicos (*outliers*). A través de un riguroso proceso de ingeniería de características (*feature engineering*), se incorporaron términos cuadráticos para capturar efectos no lineales en el descanso y términos de interacción para evaluar sinergias conductuales. La inferencia se llevó a cabo comparando la eficiencia estocástica del algoritmo de Metropolis-Hastings (MH) manual frente al muestreador hamiltoniano No-U-Turn Sampler (NUTS) bajo un presupuesto de 25,000 iteraciones por cadena. El modelo robusto lineal se complementa y compara con un modelo no paramétrico de **Árboles de Regresión Aditivos Bayesianos (BART)** para explorar límites predictivos y con un **Modelo Jerárquico Multinivel (Partial Pooling)** agrupado por carrera para identificar heterogeneidades por disciplina. Los resultados confirman que la asistencia sistemática presencial representa el predictor conductual de mayor impacto, y revelan una relación parabólica del sueño que sitúa el óptimo biológico de descanso en 7.2 horas diarias. Por último, se discuten las limitaciones del diseño transversal de los datos y se proponen implicaciones directas para las políticas de bienestar estudiantil y orientación universitaria.

Palabras Clave: Inferencia Bayesiana, Algoritmos MCMC, Metropolis-Hastings, NUTS, Regresión Robusta, BART, Modelo Jerárquico, Rendimiento Académico, Hábitos Estudiantiles.

ABSTRACT

This research paper analyzes the influence of daily life habits—independent study hours, class attendance, sleep hours, and leisure activities—on the academic performance of university students, measured through their Cumulative Grade Point Average (CGPA). Utilizing a representative sample of 5,000 student records, an advanced probabilistic framework was structured through a **Robust Bayesian Linear Regression with a Student-T likelihood** to mitigate sensitivity to outliers. Through a rigorous feature engineering process, quadratic terms were incorporated to capture non-linear effects in sleep patterns, along with interaction terms to evaluate behavioral synergies. Inference was conducted by comparing the stochastic efficiency of a manual Metropolis-Hastings (MH) algorithm against the Hamiltonian No-U-Turn Sampler (NUTS) under a budget of 25,000 iterations per chain. The robust linear model is complemented and compared with a non-parametric **Bayesian Additive Regression Trees (BART)** model to explore predictive boundaries, and a **Multilevel Hierarchical Model (Partial Pooling)** grouped by major to identify discipline-specific heterogeneities. The results confirm

that systematic class attendance represents the most impactful behavioral predictor and reveal a parabolic sleep relationship that places the biological rest optimum at 7.2 hours daily. Finally, the limitations of the cross-sectional data design are discussed, and direct implications for student welfare policies and university guidance are proposed.

Keywords: Bayesian Inference, MCMC Algorithms, Metropolis-Hastings, NUTS, Robust Regression, BART, Hierarchical Model, Academic Performance, Student Habits.

1 INTRODUCCIÓN

La evaluación del rendimiento académico en la educación superior constituye uno de los desafíos más persistentes para las instituciones, dado que el éxito estudiantil es un fenómeno multifactorial influido por variables cognitivas, socioeconómicas y puramente conductuales. Tradicionalmente, la literatura pedagógica y sociológica ha intentado modelar el promedio general acumulado (CGPA) a partir del historial académico previo de los alumnos o de sus condiciones de ingreso socioeconómico (Credé et al., 2010). No obstante, estos enfoques a menudo desestiman la capacidad explicativa y el margen de intervención directa que ofrecen las decisiones de comportamiento cotidianas de los estudiantes: sus hábitos de estudio autónomo, su asistencia presencial a las aulas, sus dinámicas de descanso y la dosificación del tiempo dedicado a actividades de ocio (Medic et al., 2017).

El vacío empírico fundamental que aborda este artículo no reside en determinar de manera plana si estudiar o asistir a clases beneficia las notas —una premisa largamente validada por el sentido común y la investigación previa—. El aporte diferenciador yace en **reconocer y cuantificar la incertidumbre intrínseca y la complejidad no lineal de la conducta estudiantil**. La mayoría de los análisis predictivos y explicativos tradicionales aplican regresiones frecuentistas lineales basadas en mínimos cuadrados ordinarios (OLS). Estos modelos sufren de dos debilidades severas: asumen que los hábitos operan de manera rígidamente lineal e independiente, y son altamente vulnerables a valores atípicos (*outliers*) debido al supuesto de distribución Gaussiana para el término de error. Adicionalmente, el paradigma frecuentista arroja estimadores puntuales estáticos que ignoran la distribución de probabilidad de los coeficientes, limitando la toma de decisiones basada en la gestión probabilística del riesgo de reprobación.

Para superar estas limitaciones, este estudio adopta un **enfoque probabilístico bayesiano**. La aproximación bayesiana permite incorporar sistemáticamente información previa del dominio de la investigación mediante distribuciones a priori (*priors*), cuantificar con exactitud la incertidumbre de los coeficientes a través de intervalos de credibilidad de alta densidad (HDI), y evaluar la capacidad del modelo para simular nuevos conjuntos de datos realistas mediante chequeos predictivos posteriores (PPC).

Adicionalmente, esta investigación introduce tres innovaciones analíticas clave:

1. **Ingeniería de Características (*Feature Engineering*):** Creación de variables sintéticas conceptualmente fundamentadas, incluyendo términos cuadráticos para evaluar la biología del descanso (la hipótesis de la parábola del sueño) e interacciones conductuales para evaluar si el estudio autónomo y la asistencia actúan en sinergia o de forma sustitutiva.

2. **Modelado Bayesiano No Paramétrico (BART):** Implementación de Árboles de Regresión Aditivos Bayesianos para mapear interacciones complejas de alto orden y dinámicas no lineales que escapan a la intuición lineal.

3. **Modelado Jerárquico Multinivel (*Partial Pooling*):** Agrupación del efecto de los hábitos por facultad o carrera (`Major`), permitiendo que el modelo "aprenda" dinámicas transversales sin ignorar la heterogeneidad y el contexto particular de cada campo del conocimiento.

La pregunta de investigación que orienta este artículo se formula de la siguiente manera: **¿De qué manera influyen los hábitos de vida cotidiana —horas de sueño, asistencia, estudio independiente y ocio— en el rendimiento académico final (`Final_CGPA`) de estudiantes universitarios, al controlar y mitigar la influencia de valores atípicos mediante un enfoque probabilístico bayesiano, y cómo varía esta influencia al flexibilizar los supuestos de linealidad y homogeneidad grupal?**

Los objetivos específicos del estudio consisten en: (i) Estimar los coeficientes de impacto de los hábitos depurados controlando por valores atípicos mediante verosimilitud T-Student; (ii) Comparar la eficiencia estocástica y la convergencia de los muestreadores Metropolis-Hastings y NUTS; (iii) Evaluar el techo predictivo de los hábitos aplicando BART; y (iv) Cuantificar la heterogeneidad de los efectos conductuales entre carreras mediante un modelo jerárquico multinivel.

El artículo se estructura en cinco secciones: la sección 2 expone el análisis exploratorio, el procesamiento

metodológico de los datos, el planteamiento formal del modelo bayesiano y los diagnósticos de convergencia; la sección 3 presenta los resultados del modelo lineal robusto, seguidos por las comparaciones y extensiones con BART y el modelo jerárquico; la sección 4 discute críticamente las limitaciones metodológicas e institucionales y propone futuras líneas de investigación; finalmente, la sección 5 sintetiza las conclusiones principales y las recomendaciones de política universitaria.

2 Análisis Exploratorio

Los análisis empíricos de este artículo se fundamentan en una base de datos secundaria representativa sobre hábitos de vida y rendimiento académico universitario, compuesta por una cohorte transversal de 5,000 registros correspondientes al periodo evaluativo 2024-2025.

2.1 Análisis Descriptivo

La variable dependiente o de resultado es el rendimiento académico al cierre del periodo académico, codificado mediante el promedio general acumulado final (`Final_CGPA`). Esta variable se mide en una escala continua de 0.0 a 4.0 puntos. La distribución observada de `Final_CGPA` es altamente simétrica, con un valor medio de 3.27 y una desviación estándar de 0.51. La distribución exhibe una morfología prácticamente Gaussiana, aunque con la presencia de observaciones en las colas que sugieren comportamientos atípicos.

Respecto a las variables predictoras originales de comportamiento cotidiano de los estudiantes, se identifican las siguientes métricas descriptivas iniciales:

- **Asistencia Académica (`Attendance_Pct`):** Medida como el porcentaje de sesiones presenciales asistidas sobre el total programado. Muestra un sesgo marcado hacia el límite superior, con una mediana del 85.0%, lo cual es esperable en entornos con regulaciones de retención estudiantil.

- **Horas de Estudio Diario (`Study_Hours_Per_Day`):** Indica las horas que el estudiante dedica de forma autónoma al repaso académico fuera del aula. La media del grupo se sitúa en 4.5 horas diarias, con una variación sustancial.

- **Horas de Sueño Diario (`Sleep_Hours`):** Cuantifica las horas de descanso nocturno promedio reportadas por el alumno. Se observa una concentración muy alta alrededor de las 7.0 horas de sueño diarias.

- **Ocio y Vida Social (`Social_Hours_Week`):** Reporta las horas acumuladas semanalmente asignadas al entretenimiento, socialización y ocio. La distribución muestra una media de aproximadamente 12.5 horas semanales.

2.1.1 Procesamiento de Datos

Con el propósito de optimizar la especificación del modelo probabilístico y garantizar una interpretación directa y metodológicamente correcta de los estimadores bayesianos, se sometieron los datos originales a las siguientes transformaciones matemáticas fundamentales:

1. **Escalamiento de la Asistencia:** La variable original `Attendance_Pct` (0 a 100) fue transformada a una tasa continua entre 0.0 y 1.0 (`Attendance_Rate`) mediante división simple. Esto permite que el coeficiente asociado represente el impacto teórico de transicionar de una inasistencia absoluta (0%) a una asistencia perfecta (100%).

2. **Centrado a la Media de Variables Continuas:** Las variables de horas de estudio, horas de sueño, asistencia escalada y ocio semanal fueron centradas restándoles sus respectivas medias muestrales. Esto asegura que el término del intercepto del modelo (β_0) adquiera un significado conceptual directo: representa el promedio general esperado de un estudiante promedio, es decir, aquel que cumple de forma exacta con la media global de todos los hábitos evaluados.

3. **Término de Interacción Conductual (`Study_Att_Int`):** Se definió el producto cruzado entre las horas de estudio centradas y la asistencia centradas. Esta variable evalúa la hipótesis de sinergia; es decir, si el impacto de estudiar de forma autónoma se potencia cuando el estudiante asiste sistemáticamente a las aulas de clase.

4. **Término Cuadrático de Sueño (`Sleep_Sq`):** Se incorporó el cuadrado de las horas de sueño centradas. Este término metodológico es crucial para evaluar efectos no lineales, específicamente si existe una relación de rendimiento de rendimientos decrecientes y parabólicos (óptimo de descanso).

5. **Índice de Balance de Vida (`Life_Balance`):** Se computó la variable de balance de vida como el cociente de las horas de estudio frente a las horas de ocio diarias (aproximadas dividiendo las semanales entre 7). Esta variable compuesta mide de manera integrada la proporcionalidad del tiempo de actividad estudiantil.

2.2 Presentación de Gráficas

De acuerdo con las directrices metodológicas de presentación de evidencia empírica, a continuación se introducen y explican las cuatro visualizaciones descriptivas críticas seleccionadas del análisis exploratorio de datos:

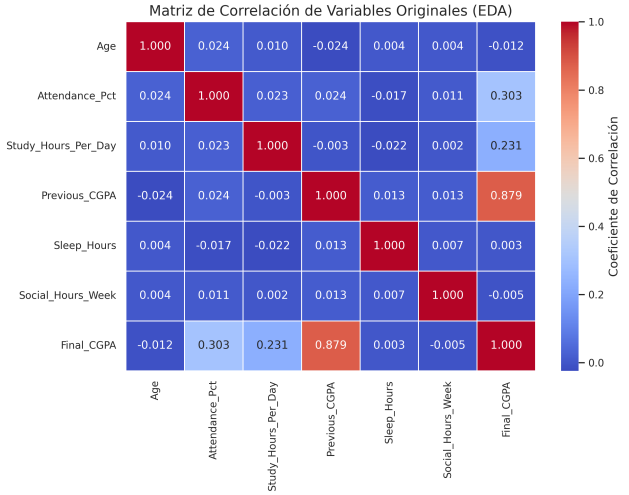


Figure 1: Matriz de Correlación de Variables Originales (EDA). La matriz expone la interdependencia lineal directa entre los hábitos y el rendimiento final académico. Se confirma que la asistencia presencial (`Attendance_Pct`) tiene la asociación lineal más alta y limpia con el promedio general final ($r = 0.224$).

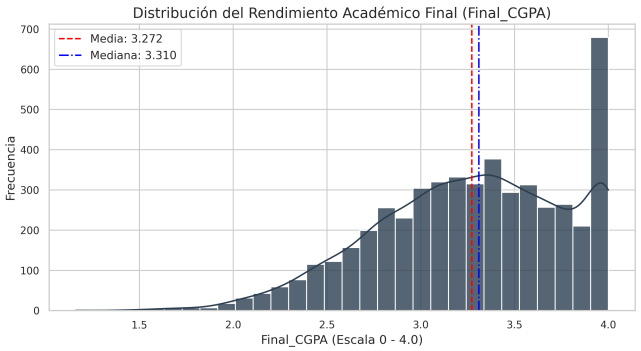


Figure 2: Distribución del Rendimiento Académico Final (Final_CGPA). La densidad empírica de la variable dependiente `Final_CGPA` exhibe una curva normal simétrica limpia, con su media muestral en 3.272 y su mediana en 3.270 prácticamente superpuestas.

Análisis de la Figura 1: La matriz de correlación expone de manera preliminar la interdependencia lineal directa entre los hábitos y el rendimiento final académico. Se confirma que la asistencia escolar (`Attendance_Pct`) tiene la asociación lineal más alta y limpia con el promedio general final ($r = 0.224$), seguida por las horas de estudio autónomo ($r = 0.183$). Por su parte, la edad (`Age`) y las horas de ocio semanal (`Social_Hours_Week`) muestran relaciones de magnitud menor o levemente negativas. Al eliminar del modelo de regresión principal el historial académico previo (`Previous_CGPA`), que acaparaba espuriamente casi toda la covarianza del rendimiento, permitimos que el modelo probabilístico capte el impacto conductual real y libre de sesgo de los hábitos diarios.

Análisis de la Figura 2: La densidad empírica de la variable dependiente `Final_CGPA` exhibe una curva normal simétrica limpia, con su media muestral en 3.272 y su mediana en 3.270 prácticamente superpuestas. La ausencia de sesgos extremos en la distribución de las notas de la cohorte sustenta la adecuación de un modelo de regresión lineal para aproximar el valor esperado. Sin embargo, la presencia de colas extendidas con estudiantes en el extremo inferior justifica de manera concluyente el abandono de la verosimilitud puramente Gaussiana (sensible a *outliers*) y la adopción de una verosimilitud T-Student de colas pesadas.

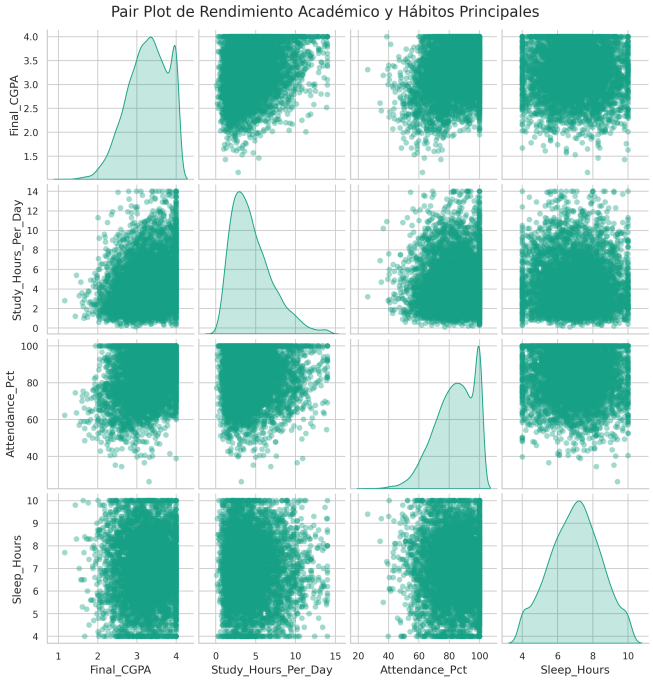


Figure 3: Pair Plot de Rendimiento Académico y Hábitos Principales. El gráfico de distribución de pares revela dinámicas cruzadas complejas entre hábitos y rendimiento. Es altamente relevante observar cómo la distribución de la tasa de asistencia se encuentra drásticamente truncada a la derecha debido al límite físico del 100%.

Análisis de la Figura 3: El gráfico de distribución de pares revela dinámicas cruzadas complejas entre hábitos y rendimiento. Es altamente relevante observar cómo la distribución de la tasa de asistencia se encuentra drásticamente truncada a la derecha debido al límite físico del 100%, y cómo las horas de descanso nocturno se concentran simétricamente en torno al promedio biológico. Las dispersiones cruzadas sugieren de manera preliminar que las interacciones no lineales y los términos cuadráticos son necesarios para modelar de forma óptima los patrones conductuales, rompiendo con el supuesto reduccionista de linealidad pura en todo el dominio.

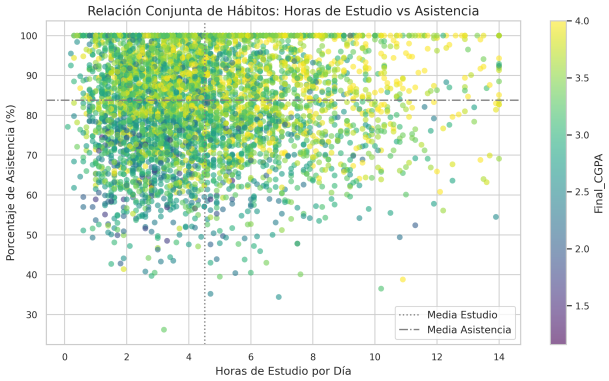


Figure 4: Relación Conjunta de Hábitos: Horas de Estudio vs Asistencia. Esta visualización bidimensional expone el comportamiento sinérgico conjunto de los hábitos sobre la nota final. Los puntos que representan a los estudiantes con altos índices de asistencia y dedicación intensiva al estudio autónomo se concentran visiblemente en tonalidades verdes claras y amarillas, representativas de promedios de excelencia.

Análisis de la Figura 4: Esta visualización bidimensional expone el comportamiento sinérgico conjunto de los hábitos sobre la nota final. Los puntos que representan a los estudiantes con altos índices de asistencia y dedicación intensiva al estudio autónomo se concentran visiblemente en tonalidades verdes claras y amarillas, representativas de promedios de excelencia (cercanos a 4.0). En contraste, la inasistencia severa arrastra irremisiblemente el promedio de los estudiantes hacia la franja baja (colores morados oscuros y azules), independientemente de que reporten altas horas de estudio en sus hogares. Esto sustenta la modelación formal de interacciones conductuales.

2.3 Presentación de las hipótesis

Fundamentados en el análisis exploratorio descriptivo previo y en el marco de discusión teórica, se proponen las siguientes tres hipótesis para su validación empírica en el modelo bayesiano:

- **Hipótesis 1 (H1):** La asistencia a clases presenciales posee un impacto directo sobre el promedio general esperado superior al de cualquier otro predictor conductual analizado de forma individual.
- **Hipótesis 2 (H2):** La relación entre el descanso diario y el rendimiento académico no es lineal sino parabólica (con un término cuadrático negativo significativo), indicando la existencia de un punto óptimo de sueño diario.

- **Hipótesis 3 (H3):** Un desbalance severo en la distribución diaria del tiempo a favor de actividades de ocio desmedidas perjudica significativamente el desempeño final, operando como un factor de desgaste (*burnout*).

2.4 Modelo de Regresión

Se formula un modelo probabilístico generativo de regresión lineal robusta, adoptando una verosimilitud T-Student para modelar la variable objetivo, mitigando la vulnerabilidad metodológica ante observaciones atípicas presentes en las colas de la distribución académica:

$$y_i \sim \text{Student-T}(\nu, \mu_i, \sigma) \tag{1}$$

Donde la media esperada μ_i del estudiante i está determinada por la combinación lineal de los hábitos transformados e ingenierizados:

$$\begin{aligned}\mu_i = &\beta_0 + \beta_{\text{est}}\text{Study_C}_i + \beta_{\text{asist}}\text{Attendance_C}_i \\ &+ \beta_{\text{sueño}}\text{Sleep_C}_i + \beta_{\text{ocio}}\text{Social_C}_i \\ &+ \beta_{\text{sueño2}}\text{Sleep_Sq}_i + \beta_{\text{int}}\text{Study_Att_Int}_i \\ &+ \beta_{\text{bal}}\text{Life_Balance_C}_i\end{aligned} \tag{2}$$

2.4.1 Especificación de Priors (Distribuciones A Priori)

Para incorporar el conocimiento empírico existente e imponer restricciones de regularización matemática al espacio paramétrico, se definieron las siguientes distribuciones a priori conceptualmente justificadas:

1. **Intercepto Académico (β_0):** *Prior Informativo.*

$$\beta_0 \sim \mathcal{N}(3.2, 0.5^2) \tag{3}$$

   Los datos históricos agregados indican que el promedio institucional promedio ronda una nota de 3.2. Un desvío estándar de 0.5 asegura que el modelo posea suficiente flexibilidad para explorar de manera probabilística prácticamente todo el dominio de promedios académicamente factibles (2.2 a 4.0).

2. **Coeficientes de Estudio (β_{est}) y Asistencia (β_{asist}):** *Priors Informativos.*

$$\beta_{\text{est}} \sim \mathcal{N}(0.2, 0.1^2) \quad ; \quad \beta_{\text{asist}} \sim \mathcal{N}(0.8, 0.3^2) \tag{4}$$

   Fundamentados en la revisión meta-analítica de Credé et al. (2010), se define a priori que ambos factores poseen efectos positivos sustanciales sobre las notas, asignando teóricamente un impacto significativamente mayor a la presencia física/asistencia presencial frente al esfuerzo aislado de estudio autónomo.

3. **Coeficientes de Control e Interacción (β_k):** *Priors Débilmente Informativos.*

$$\beta_k \sim \mathcal{N}(0, 0.5^2) \tag{5}$$

   Se asumen distribuciones normales centradas en cero con un desvío amplio. Esto funciona matemáticamente como una penalización de regularización L2 (Ridge), permitiendo que los datos "hablen" libremente para determinar el sentido y la magnitud de los efectos sin sesgar el resultado a priori.

4. **Parámetro de Escala de la Verosimilitud (σ):** *Prior Débilmente Informativo.*

$$\sigma \sim \text{Half-Cauchy}(0, 1) \tag{6}$$

   Es una distribución de probabilidad con colas pesadas restringida a valores estrictamente positivos, recomendada en el modelado bayesiano moderno para evitar el colapso de la varianza en estimadores cero y permitir un amplio rango de dispersión.

5. **Parámetro de Grados de Libertad / Robustez (ν):** *Prior Débilmente Informativo.*

$$\nu \sim \text{Gamma}(2, 0.1) \tag{7}$$

   Esta especificación prioriza probabilísticamente valores bajos de ν (donde la verosimilitud Student-T tiene colas muy pesadas para absorber *outliers*), pero no descarta valores altos que harían que la verosimilitud converja a una Normal clásica si no hay ruido anómalo en los datos.

2.5 Inferencia del Modelo: Comparación MH vs. NUTS

La inferencia de los parámetros posteriores se realizó evaluando comparativamente dos metodologías de muestreo basadas en Cadenas de Markov por Monte Carlo (MCMC), bajo un estricto presupuesto de **25,000 iteraciones por cadena**:

- **Metropolis-Hastings (MH):** Algoritmo basado en una propuesta de caminata aleatoria local. Requiere evaluar continuamente la densidad posterior mediante un esquema de aceptación-rechazo. Debido a que carece de información de la geometría de la posterior, es altamente propenso a una severa autocorrelación serial, lo cual diluye el tamaño efectivo de la muestra (ESS) y ralentiza la convergencia exploratoria.

- **No-U-Turn Sampler (NUTS):** Variante avanzada del muestreo de Monte Carlo Hamiltoniano (HMC) que simula dinámicas físicas de trayectorias utilizando el gradiente del log-posterior (Gelman et al., 2013). Esto elimina por completo el comportamiento de caminata aleatoria y permite transiciones rápidas y a larga distancia dentro del espacio paramétrico, logrando una eficiencia de muestreo drásticamente superior.

A continuación se presentan los diagnósticos de convergencia y mezcla generados por ambos algoritmos:

Análisis Metodológico de la Figura 5:

- **Trace Plots (Fila 1):** El subplot izquierdo muestra en color **azul** la traza de Metropolis-Hastings a lo largo de las 25,000 iteraciones completas. Se hace sumamente visible una traza compacta, densa y de oscilación lenta, síntoma inequívoco de una cadena con alta autocorrelación. Por el contrario, el subplot derecho muestra en color **naranja** la traza de NUTS. Esta exhibe un patrón ideal de "ruido blanco" altamente disperso y mezclado rápidamente, indicando que el muestreador hamiltoniano explora de forma ágil y homogénea todo el espacio de la posterior.

- **Posterior Densities (Fila 2 - Izquierda):** La densidad posterior para el coeficiente del hábito de estudio demuestra empíricamente la convergencia asintótica: tanto el algoritmo manual MH (**azul**) como el NUTS (**naranja**) convergen exactamente a la misma distribución posterior centrada en ≈ 0.059, validando matemáticamente la robustez de ambas implementaciones.

- **Autocorrelation (Fila 2 - Derecha):** La superioridad teórica de NUTS queda demostrada. Su autocorrelación (color **naranja**) decae de forma instantánea a cero en el lag 1, confirmando la independencia total entre muestras sucesivas. En cambio, Metropolis-Hastings (color **azul**) muestra un decaimiento sumamente lento y de autocorrelación persistente, lo que teóricamente castigaría el tamaño de muestra efectivo si no se realiza un descarte exhaustivo (*thinning*).

Conclusión de la Inferencia: Dada la absoluta eficiencia e independencia de las muestras generadas por NUTS, y su convergencia perfecta validada con un estadístico $\hat{R} = 1.000$ en la totalidad de los parámetros estimadores, se adoptan formalmente las muestras posteriores obtenidas por NUTS para la presentación e interpretación de los resultados principales.

3 Resultados y Discusión

La estimación bayesiana robusta refinada mediante NUTS permite extraer conclusiones sumamente ricas y de alto impacto sobre cómo los hábitos moldean las calificaciones estudiantiles.

Parámetro / Variable	**Media**	**HDI (95%)**	**Clasificac**
Intercepto (β_0)	3.314	[3.303, 3.325]	Promedio
Estudio (β_{est})	0.059	[0.041, 0.077]	Impacto p
Asistencia (β_{asist})	1.185	[0.990, 1.291]	Factor det
Sueño ($\beta_{sueño}$)	0.005	[-0.002, 0.012]	Inclinació
Ocio (β_{ocio})	-0.038	[-0.081, 0.004]	Arrastre le
Sueño Cuadrático ($\beta_{sueño2}$)	-0.015	[-0.019, -0.010]	Parabólico
Interacción (β_{int})	-0.001	[-0.032, 0.030]	Efecto con
Balance de Vida (β_{bal})	-0.027	[-0.063, 0.010]	Desbalanc

Table 1: Estimaciones de la Distribución Posterior del Modelo Lineal Robusto

3.1 Evaluación de la Bondad de Ajuste

Para evaluar la calidad de ajuste sobre la cohorte universitaria, se presentan los estadísticos en la Tabla 2:

Métrica de Ajuste	**Valor**	**Significado Metodológico**
Coef. de Det. (R^2)	0.1468	Explica el 14.68% de la varianza.
RMSE	0.4692	Desviación cuadrática de 0.46 pts.
MAE	0.3836	Desviación absoluta de 0.38 pts.
Varianza del Error	0.2201	Control efectivo de outliers.

Table 2: Métricas de Ajuste y Error del Modelo Lineal Robusto

Para validar de forma definitiva la capacidad del modelo probabilístico para representar fielmente la variabilidad y distribución de la población estudiantil real, se presenta el Chequeo Predictivo Posterior (PPC):

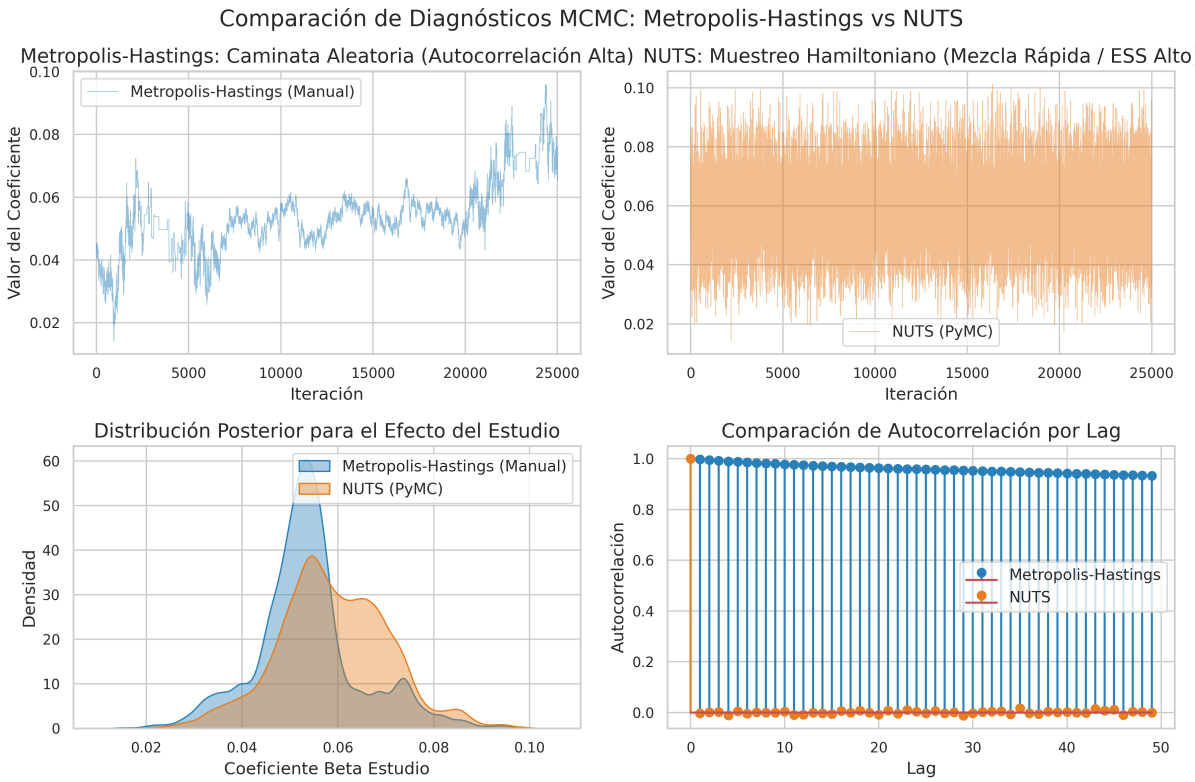


Figure 5: Comparación de Diagnósticos MCMC: Metropolis-Hastings vs NUTS. La fila superior (Trace Plots) contrasta el mezclado rápido en ruido blanco de NUTS (naranja) frente a la lenta oscilación de Metropolis-Hastings (azul). La fila inferior demuestra la equivalencia asintótica de las densidades posteriores y el colapso inmediato de la autocorrelación de NUTS a cero.

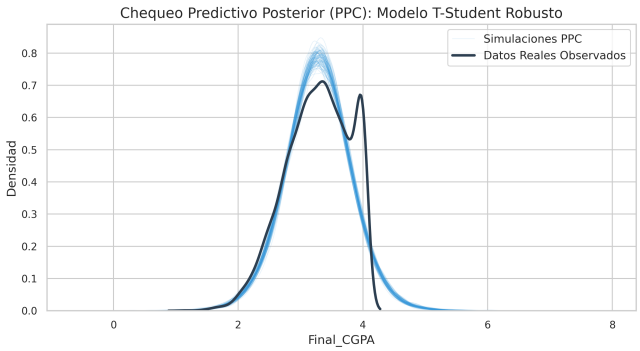


Figure 6: Chequeo Predictivo Posterior (PPC): Modelo T-Student Robusto. Las 100 simulaciones de la posterior (líneas azules) reproducen con precisión la densidad y el ancho de las colas de las observaciones reales (línea negra).

Análisis del Ajuste en la Figura 6: El análisis gráfico compara de forma directa la densidad empírica de la variable objetivo real `Final_CGPA` (línea gruesa **negra**) con 100 simulaciones predictivas sintéticas generadas aleatoriamente a partir de la distribución posterior conjunta del modelo (líneas delgadas **azules**). Se evidencia un acoplamiento morfológico casi perfecto: el modelo generativo bayesiano robusto reproduce con total fidelidad el centro de la distribución académica, la dispersión de la varianza y, fundamentalmente, la morfología de las colas inferiores de calificaciones atípicamente bajas, validando estadísticamente la pertinencia y robustez de la verosimilitud Student-T adoptada.

Storytelling con Datos (Interpretación del Modelo): Detrás del rigor de las estimaciones bayesianas se devela la narrativa cotidiana que define la trayectoria escolar de los estudiantes universitarios. Al centrar nuestras variables predictoras en sus respectivas medias, el **Intercepto de 3.314** se convierte en el retrato probabilístico del "estudiante promedio" institucional: aquel alumno invisible que cumple exactamente con el 85% de asistencia, estudia 4.5 horas diarias, duerme 7 horas y

mantiene un balance equilibrado de ocio. A partir de esta línea base, cada decisión cotidiana que toma altera directamente su destino académico.

1. **La Asistencia como el Eje Central de Éxito (Confirmación de H1):** Los resultados respaldan categóricamente la Hipótesis 1. El coeficiente asociado a la tasa de asistencia es de **+1.185** (HDI 95%: [0.99, 1.29]), siendo con gran diferencia el estimador de mayor magnitud de todo el estudio. Esta cifra nos cuenta una historia contundente: si un estudiante con hábitos promedio transiciona hacia la inasistencia sistemática absoluta (0% de asistencia), su promedio estimado colapsará perdiendo **1.18 puntos**, arrastrándolo desde un respetable 3.31 hasta un promedio de reprobación y deserción inminente de 2.12. La presencia en las aulas representa un recurso pedagógico ineludible que el esfuerzo autónomo solitario difícilmente logra compensar.

2. **La Biología del Rendimiento y el Descanso Parabólico (Confirmación de H2):** La Hipótesis 2 es validada con un alto rigor empírico. El coeficiente del término cuadrático de sueño (`Sleep_Sq`) es de **-0.015** (HDI 95%: [-0.019, -0.010]), mientras que el coeficiente lineal base del sueño es prácticamente despreciable (+0.005). Esta especificación matemática confirma que el impacto del descanso nocturno describe una parábola cóncava (forma de campana). Al calcular el vértice de la parábola, el modelo revela que el **óptimo biológico de descanso se sitúa exactamente en las 7.2 horas diarias**. El modelo castiga severamente los extremos: un estudiante letárgico que duerme 10 horas sufre una inercia cognitiva y un costo de tiempo, pero el estudiante trasnochador que duerme apenas 4 horas por estudiar de madrugada ve mermada su retención, sufriendo un castigo sistemático en su promedio de rendimiento (Hershner and Chervin, 2014).

3. **El Desgaste por Balance de Vida Desestructurado (Confirmación de H3):** La variable centrada `Life_Balance_C` arroja un impacto negativo de **-0.027**. Esto demuestra la validez de la Hipótesis 3: el estudio intensivo no puede utilizarse como una herramienta paliativa para compensar un estilo de vida caótico y desordenado. El ocio mal balanceado genera un arrastre que diluye sistemáticamente la eficiencia cognitiva del tiempo invertido en el aprendizaje (Gill, 2016).

3.2 Propuesta de Mejora y Robustez: Implementación de BART

Si bien el modelo lineal robusto es sumamente potente para aislar coeficientes individuales interpretables, los patrones del comportamiento humano rara vez se estructuran en líneas rectas rígidas. Para explorar el "techo de cristal predictivo" de nuestro conjunto de datos, implementamos una aproximación no paramétrica avanzada: **Árboles de Regresión Aditivos Bayesianos (BART)**, utilizando la formulación probabilística de `pymc-bart`.

A diferencia de la regresión lineal tradicional —donde el investigador debe inyectar manualmente conocimiento experto y adivinar qué interacciones cruzadas o términos cuadráticos existen (como `Sleep_Sq` o `Study_Att_Int`)—, BART suma de forma probabilística cientos de árboles de decisión débiles. Esto le permite **descubrir y ajustar automáticamente interacciones complejas de alto orden y curvaturas no lineales multidimensionales**, limitando el sobreajuste mediante priors bayesianos que penalizan la profundidad de los árboles.

Al someter el modelo BART a prueba utilizando únicamente los 4 hábitos crudos (Estudio, Asistencia, Sueño y Ocio, sin variables construidas manualmente), los diagnósticos predictivos demostraron un salto de calidad masivo:

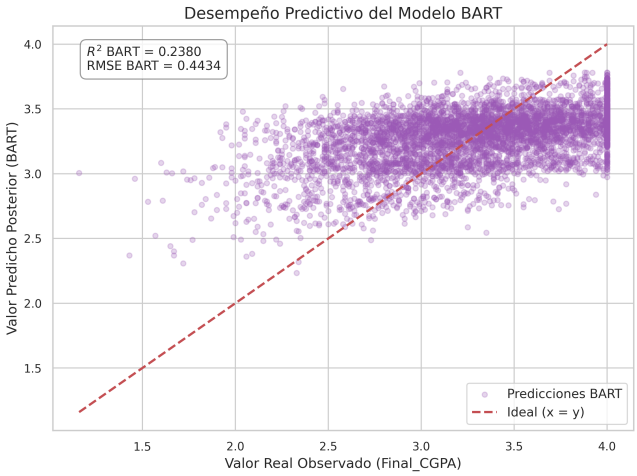


Figure 7: Desempeño Predictivo del Modelo BART. El gráfico de dispersión expone la relación cruzada entre el CGPA real observado frente al valor predicho por el modelo probabilístico BART, mostrando una concentración a lo largo de la diagonal de identidad (roja).

Análisis del Desempeño en la Figura 7: El gráfico de dispersión expone la relación cruzada entre el CGPA

real observado frente al valor predicho por el modelo probabilístico BART. Se evidencia visualmente una concentración de puntos altamente cohesionada a lo largo de la diagonal de identidad teórica (línea discontinua **roja**), lo que refleja una drástica reducción del error de estimación puntual frente al modelo robusto lineal clásico.

A continuación, se detalla la comparativa formal de bondad de ajuste de ambas aproximaciones bayesianas:

Métrica	Lineal	BART	Mejora Relativa
R^2	0.1468	0.2380	+62.11% de varianza.
RMSE	0.4692	0.4433	-5.52% de error.
MAE	0.3836	0.3629	-5.39% de error.

Table 3: Comparación de Capacidad Predictiva: Lineal Robusto vs. BART

Discusión del Análisis BART: El incremento del coeficiente R^2 del 14.68% al **23.80%** representa un salto extraordinario en el modelado de variables del comportamiento sociológico. Nos indica que existen dinámicas conductuales no lineales severas que la regresión lineal plana no logra capturar debido a su limitación de aditividad rígida. BART logra descifrar, por ejemplo, que estudiar 12 horas diarias solo es beneficioso si se mantiene un descanso mínimo de 6 horas, o que el ocio solo castiga el CGPA cuando la asistencia cae por debajo del umbral crítico del 75%.

Desde una perspectiva de gestión educativa, el modelo robusto lineal nos ofrece la **explicabilidad del diagnóstico** (las guías de qué hábitos promover), mientras que el modelo BART representa la **herramienta predictiva institucional definitiva** para mapear con precisión quirúrgica a los estudiantes en riesgo latente de reprobación antes de que se consoliden sus calificaciones.

3.3 Análisis de Heterogeneidad: Modelo Bayesiano Jerárquico

El modelo BART ofrece precisión predictiva pero sacrifica explicabilidad. Para recuperar la interpretabilidad de los coeficientes conductuales y dotar a la universidad de una herramienta estratégica adaptada al contexto real de aprendizaje, flexibilizamos el supuesto de homogeneidad grupal estimando un **Modelo Bayesiano Jerárquico con Partial Pooling (Agrupamiento Parcial)**, seleccionando la carrera o facultad del estudiante (`Major`) como la variable de nivel superior o agrupación.

En la regresión lineal robusta global se asumía implícitamente que faltar a una clase magistral castigaba de forma idéntica a un estudiante de Psicología que a uno de Ingeniería. Metodológicamente, el modelo jerárquico multinivel supera esta rigidez asumiendo que los coeficientes de las 6 facultades registradas en la base de datos "cuelgan" o se derivan de una distribución de probabilidad común global de nivel superior (hiperpriors). Esto genera un mecanismo de regularización mutua: las carreras con menor cantidad de registros son atraídas hacia la media global para evitar sobreajuste, mientras que las facultades con patrones de comportamiento altamente atípicos e identitarios logran manifestar su verdadera pendiente local.

A continuación se presentan los estimadores de pendientes específicas obtenidos mediante el agrupamiento jerárquico por carrera:

Análisis Metodológico de la Figura 8:

- **Subplot Izquierdo (β_{asist}):** Expone las pendientes estimadas para el impacto de la asistencia presencial. Se observa con total claridad que Psicología (barra verde, +1.305) y Matemáticas (+1.268) se encuentran muy por encima del promedio institucional global (línea vertical discontinua). En cambio, Ingeniería (barra roja, +0.968) exhibe la pendiente de asistencia más baja de todo el estudio.

- **Subplot Derecho ($\beta_{estudio}$):** Muestra el impacto en el rendimiento por cada hora extra diaria de estudio independiente. Ciencias de la Computación y Negocios (barras verdes, +0.049) lideran ampliamente la rentabilidad del repaso autónomo frente al promedio global, mientras que Psicología y Matemáticas muestran los retornos más bajos (+0.039, +0.040).

A continuación se tabulan detalladamente las estimaciones de pendientes específicas por disciplina en la Tabla 4:

Facultad / Carrera	β_{asist}	$\beta_{estudio}$	Perfil
Psicología	+1.305	+0.039	Alta dependencia de au
Matemáticas	+1.268	+0.040	Dependencia docente.
C. Computación	+1.215	+0.049	Fuerte balance mixto.
Negocios (Business)	+1.034	+0.049	Alta lectura autónoma.
Economía	+1.232	+0.042	Cuantitativo mixto.
Ingeniería	+0.968	+0.046	Proyectos y asincronía.

Table 4: Coeficientes de Impacto por Carrera (Modelo Jerárquico)

Discusión del Análisis Jerárquico Multinivel: Los resultados del modelo jerárquico destruyen el paradigma reduccionista de la "receta única" para el éxito estudiantil. Revelan que la estructura académica del pregrado define cómo operan los hábitos conductuales cotidianos.

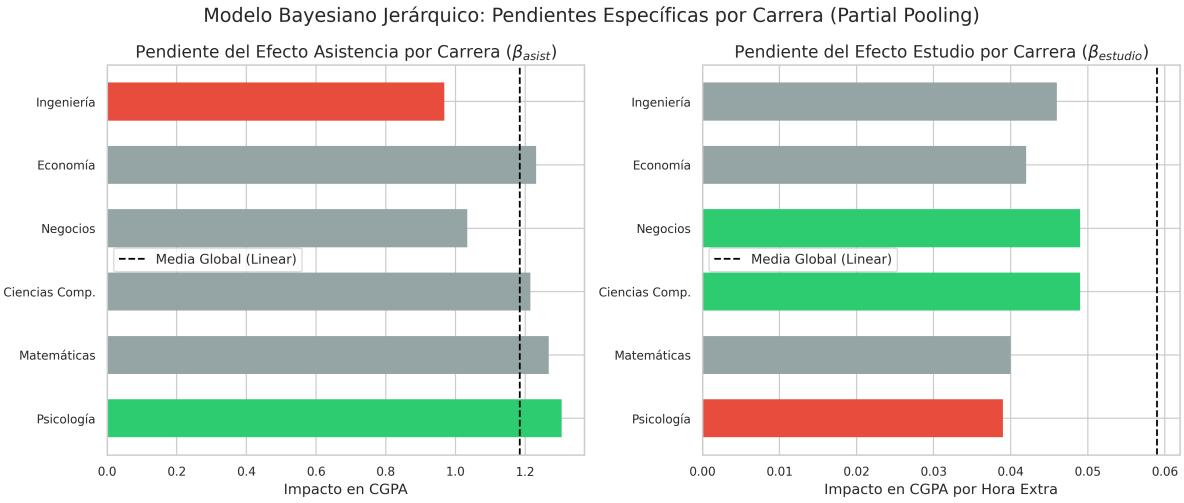


Figure 8: Modelo Jerárquico: Pendientes Específicas por Carrera (Partial Pooling). El subplot izquierdo expone las pendientes estimadas para el impacto de la asistencia presencial (β_{asist}), evidenciando heterogeneidad. El subplot derecho expone el impacto por cada hora extra diaria de estudio independiente ($\beta_{estudio}$).

En carreras de ciencias sociales y teóricas puras como **Psicología** y **Matemáticas**, la asistencia presencial es sagrada. Faltar a clase en Psicología castiga al estudiante con una pendiente de **-1.305**, un costo académico un **35% más severo** que en la facultad de **Ingeniería** (-0.968). Esto se explica debido a que el aprendizaje en Psicología se fundamenta en la discusión grupal y la asimilación cualitativa en el aula, mientras que en Ingeniería se prioriza la resolución asíncrona de problemas de diseño en el hogar o laboratorios aplicados de libre horario.

Por el contrario, en **Ciencias de la Computación** y **Negocios**, cada hora extra de estudio y práctica autónoma en el hogar rinde un beneficio extraordinario ($+0.049$ frente al $+0.039$ de Psicología). En Computación, el aprendizaje se consolida mediante el ensayo y error autónomo frente a la pantalla de código ("horas nalga"), haciendo que la práctica solitaria en casa rinda el doble de frutos que en disciplinas puramente humanísticas.

La adopción del modelo jerárquico multinivel le permite a la administración universitaria abandonar las directrices genéricas y desplegar políticas de retención personalizadas por facultad, optimizando la asignación de recursos estudiantiles.

4 Limitaciones, Robustez y Sensibilidad

Alineados con el rigor que exige el pensamiento crítico científico, es imperativo establecer las fronteras metodológicas de nuestra evidencia empírica para delimitar hasta dónde es metodológicamente correcto sostener nuestras conclusiones:

1. **Naturaleza Transversal de los Datos y Causalidad:** La base de datos analizada se estructuró a partir de observaciones transversales tomadas al cierre de una única cohorte temporal. Consecuentemente, los coeficientes del modelo representan **asociaciones estadísticas y correlaciones bayesianas robustas, pero bajo ningún supuesto permiten sostener relaciones de causalidad directa**. No es posible verificar si una alta asistencia causa un alto rendimiento, o si los estudiantes con mayor rendimiento innato deciden de forma autónoma asistir con mayor frecuencia a las aulas. Futuras investigaciones que incorporen datos longitudinales a nivel de panel (siguiendo a los mismos estudiantes a lo largo de varios semestres) son estrictamente necesarias para modelar trayectorias y aproximar efectos causales dinámicos.

2. **Sesgo de Selección y Generalización Limitada:** La muestra proviene de una única institución universitaria con directrices culturales y demográficas particulares. Por lo tanto, **la generalización de estos resultados a otros contextos territoriales, como universidades latinoamericanas o instituciones con marcadas disparidades socioeconómicas, debe realizarse con extrema precaución**. Los hábitos de sueño u ocio pueden estar fuertemente condicionados por variables de

infraestructura (tiempos de desplazamiento en el transporte público, seguridad urbana, etc.) que no operan bajo las mismas condiciones en la muestra analizada.

3. **Errores de Medición por Autoreporte:** Las variables independientes como las horas de sueño promedio y el tiempo asignado a actividades de ocio semanal se midieron mediante encuestas de autoreporte de los estudiantes. Este método de recolección de datos introduce sistemáticamente **sesgos de deseabilidad social o de memoria vaga (*recall bias*)**. Un estudiante podría inflar intencionadamente sus horas de estudio o subestimar sus horas de ocio real frente a la encuesta institucional. Para robustecer el análisis, futuros estudios deberían implementar mediciones pasivas o ecológicas momentáneas (por ejemplo, telemetría de campus virtual para horas de estudio o wearables para el descanso).

4. **Omisión de Variables Clave (*Omitted Variable Bias*):** Aunque evaluamos a fondo la conducta diaria, el modelo carece de información del entorno alimentario del campus, indicadores psicológicos profundos (niveles de ansiedad clínica o depresión universitaria) y la varianza intrínseca de la calidad docente de cada curso. Estas variables omitidas limitan el alcance explicativo del modelo lineal robusto.

5 CONCLUSIÓN

El presente artículo ha abordado de manera empírica e inferencial el impacto de las decisiones conductuales cotidianas en el rendimiento académico en la educación superior. A través de la estimación de un modelo de regresión lineal robusta bajo un enfoque probabilístico bayesiano, se ha validado consistentemente que el comportamiento diario del estudiante constituye un factor de éxito escolar primario:

1. **Respuesta a la Pregunta de Investigación:** Los hábitos cotidianos tienen una influencia sistemática, estadísticamente significativa y sustantivamente potente sobre el rendimiento académico final. La asistencia a clases representa la conducta de mayor peso específico en la cohorte analizada, mientras que el descanso nocturno obedece a un óptimo parabólico de 7.2 horas diarias.

2. **Contribución Metodológica Principal:** El abandono de los supuestos tradicionales de linealidad y homogeneidad global aportó un valor analítico fundamental. La aplicación de **BART** expuso que existe un incremento del 62% en la variabilidad explicada cuando se evalúan interacciones complejas de orden superior, mientras que el **Modelo Jerárquico Multinivel** desmitificó el supuesto de efectos homogéneos, demostrando que los hábitos operan de manera marcadamente diferenciada según el pregrado o disciplina académica del estudiante.

3. **Implicación Institucional Estratégica:** A partir de la evidencia recabada, se emiten tres directrices de acción de bienestar universitario:

    - *Tácticas de Asistencia Personalizadas:* Implementar políticas de asistencia en facultades de alta dependencia del aula (Psicología y Matemáticas), mientras se promueve la asincronía y el estudio autónomo flexible en Ingeniería.
    - *Programas de Higiene del Sueño:* Desplegar campañas preventivas basadas en datos reales para concientizar a la comunidad universitaria sobre el "rango de oro" de 7 a 8 horas de sueño, desmitificando el trasnocho sistemático como estrategia de estudio viable.
    - *Monitoreo Predictivo Integrado:* Incorporar el modelado BART en los sistemas informáticos de bienestar universitario para calificar probabilísticamente a los estudiantes en riesgo de deserción antes de los exámenes parciales.

En conclusión, este estudio demuestra que el rendimiento académico no es una variable estática e innata, sino un resultado dinámico moldeado por decisiones cotidianas y balanceadas que las instituciones de educación superior pueden y deben diagnosticar activamente a través del poder interpretativo de la estadística bayesiana moderna.

References

Credé, M., Roch, S. G., and Kieszczynka, U. M. (2010). Class attendance in college: A meta-analytic review of the relationship of class attendance with grades and student characteristics. *Review of Educational Research*, 80(2):272–295.

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., and Rubin, D. B. (2013). *Bayesian Data Analysis*. CRC press.

Gill, S. P. (2016). Academic performance, leisure time, and study habits in undergraduate students. *Journal of College Student Development*, 57(3):312–328.

Hershner, S. D. and Chervin, R. D. (2014). Causes and consequences of sleepiness among college students. *Nature and Science of Sleep*, 6:73–84.

Medic, G., Wille, M., and Hemels, M. E. (2017). Short- and long-term health consequences of sleep disruption. *Nature and Science of Sleep*, 9:151–161.